空间转录组学入门

从细胞、DNA 和蛋白质到 CS 数据与科研问题

面向计算机与人工智能专业的本科生和研究生

适用读者：有计算机或人工智能背景，但对生物学基本概念尚不熟悉的学生。本文从我们能想象的组织和细胞出发，逐步说明 RNA 怎样变成实验数据，再解释算法能用这些数据研究什么。不要求预先学过分子生物学；读到矩阵部分时，具备基本的线性代数和机器学习概念会有帮助。

写作动机：我的研究生学习领域涉及空间转录组学相关知识。在学习和研究过程中，我体会到，刚接触这一方向的同学往往需要先熟悉一些生物学概念，才能进一步理解实验数据和计算方法。因此，我整理了这份入门资料，希望把相关知识讲得更清楚一些，也帮助更多同学顺利迈出第一步。

读完后，我们应该能够用自己的话说明：空间转录组测什么、为什么要保留位置、矩阵的一行和一列代表什么，以及一个 AI 模型的输出如何成为有依据的科学结论。

先给脑中放一张简单的图

一小块组织里有许多细胞。研究人员测量不同位置的 RNA，用这些分子信号了解细胞的身份和状态，再把信息放回组织地图。这就是后面所有内容的起点。RNA 是什么、为什么能提供线索，我们接下来慢慢解释。

阶段	阅读内容	理解目标
先认识研究对象	第 1–5 章	细胞、DNA、基因、RNA、蛋白质和表达
再理解测量方法	第 6–9 章	转录组、单细胞、空间信息与实验读数
最后进入 CS 与科研	第 10–15 章	数据表示、分析流程、研究问题和验证
遇到术语时回查	第 16–17 章	核心名词及来源

贯穿全文的例子

我们假设研究人员拿到一张肿瘤组织薄片，想了解“不同细胞在哪里，以及免疫细胞是否出现在肿瘤内部”。这是一个研究问题示例，不预设答案，也不凭细胞分布直接判断治疗效果。后面的计数和布局均为教学构造。

我们不需要一次读完。前五章能讲清楚，就已经补上了理解空间转录组最关键的基础。类比帮助建立直觉，但不能代替真实的分子与实验过程。

目录

第一部分 生物学基础 5

1 先认识组织和细胞 6
1.1 组织和细胞分别在哪一层 . . . 6
1.2 细胞可以想象成一个微小的工作单位 . . . 6
1.3 为什么显微镜照片还不够 . . . 7

2 DNA 和基因究竟是什么 8
2.1 DNA 是保存遗传信息的分子 . . . 8
2.2 基因是 DNA 上具有功能的一段信息 . . . 8
2.3 染色体和基因组怎么放进这张图 . . . 8
2.4 为什么不同细胞可以拥有相似 DNA . . . 9

3 RNA 是怎样产生的 10
3.1 细胞会按照 DNA 信息制造 RNA . . . 10
3.2 mRNA 是 RNA 中的一种 . . . 10
3.3 RNA 为什么能提供细胞状态的线索 . . . 10
3.4 先把一个常见误解排除 . . . 10

4 蛋白质是什么以及怎样产生 12
4.1 蛋白质由氨基酸链组成 . . . 12
4.2 翻译把 mRNA 的信息用于制造蛋白质 . . . 12
4.3 为什么蛋白质重要 . . . 12

5 基因表达是在说什么 14
5.1 表达表示基因信息被用于产生功能产物 . . . 14
5.2 为什么相似 DNA 能产生不同细胞 . . . 14
5.3 细胞类型和细胞状态要分开 . . . 14
5.4 标志基因怎样帮助识别细胞 . . . 14
5.5 RNA 多为什么不一定等于蛋白质多 . . . 14

第二部分 测量原理与空间信息 15

6 转录组是很多 RNA 的整体情况 16
6.1 先理解为什么要加一个“组”字 . . . 16
6.2 一个基因和一个 RNA 分子不是一一对应 . . . 16
6.3 测转录组不等于测到了所有 RNA . . . 16
6.4 RNA 测量怎样帮助研究组织 . . . 16

Auutuumn

7 混在一起测和分开测有什么区别 17
7.1 第一种方式是测一份混合组织 . . . 17
7.2 第二种方式是尽量分别测每个细胞 . . . 17
7.3 单细胞核又是什么 . . . 17
7.4 我们的研究问题还缺什么 . . . 17

8 空间转录组把表达放回组织地图 18
8.1 空间转录组同时关联表达和位置 . . . 18
8.2 为什么位置有生物学意义 . . . 18
8.3 空间不意味着每一行都是一个细胞 . . . 18

9 实验怎样知道哪些 RNA 来自哪里 19
9.1 先看一种典型的测序路线 . . . 19
9.2 一份读数要回答两个问题 . . . 19
9.3 为什么多个 reads 不一定等于多个 RNA . . . 19
9.4 另一条路线是直接在组织里成像 . . . 19

第三部分 计算分析与科研实践 20

10 从 RNA 读数到基因表达矩阵 21
10.1 把 RNA 信号整理成一张表 . . . 21
10.2 从 CS 的角度理解这张矩阵 . . . 21
10.3 如何从矩阵中观察表达模式 . . . 22
10.4 矩阵里的零意味着什么 . . . 22

11 坐标、图像和文件怎样与矩阵对应 23
11.1 表达矩阵之外还要有坐标 . . . 23
11.2 表达相似和位置相邻是两种关系 . . . 23
11.3 组织图像是第三类信息 . . . 24
11.4 AnnData 和 H5AD：如何把这些数据保存在一起 . . . 25

12 空间转录组数据的常见分析流程 27
12.1 质量控制：先检查数据是否可靠 . . . 27
12.2 归一化：让不同位置的表达值更容易比较 . . . 27
12.3 特征选择与降维：从大量基因中寻找主要差异 . . . 28
12.4 聚类与注释：从表达模式理解细胞类型 . . . 28
12.5 空间分析：把表达模式放回真实组织 . . . 28
12.6 常见分析步骤总结 . . . 29

13 算法能够研究哪些问题 30

Auutuumn

13.1 问题一：组织里有哪些不同区域 30
13.2 问题二：混合区域里有什么细胞 30
13.3 问题三：能否从图像预测表达 30
13.4 问题四：哪些信号在空间上变化 30
13.5 问题五：哪些细胞可能相互影响 30

14 用一个问题串起科研全过程 31
14.1 从问题开始，而不是从模型开始 31
14.2 第一步：分清观察与推断 31
14.3 第二步：定义我们要比较的区域 31
14.4 第三步：选择与测量单位相符的方法 31
14.5 第四步：看结果是否真的支持描述 31
14.6 第五步：决定能把结论说到哪里 31

15 从 CS 模型到可信科学结论 32
15.1 大量位置不等于大量独立患者 32
15.2 训练、测试怎样分，取决于想验证什么 32
15.3 已有算法结果未必就是地面真值 32
15.4 差异表达不直接证明原因 32
15.5 读论文时先回答五个问题 32

第四部分 术语回查与延伸阅读 33

16 核心术语回查 34
16.1 如何使用这份术语表 34
16.2 核心术语与常见混淆 34

17 来源和下一步阅读 35
17.1 按学习进度安排下一步阅读 35
17.2 参考来源 35

Auutuumn

第一部分

生物学基础

第 1–5 章：从组织和细胞到基因表达

这一部分要理解什么

先认识研究对象，再认识细胞如何保存和使用信息。建立 DNA、基因、RNA、蛋白质与表达之间的联系，区分细胞类型和细胞状态，为理解实验读数做好准备。

Auutuumn

1 先认识组织和细胞

想象医生取出一小块组织，把它切成薄片，放在显微镜下。这张薄片并不是均匀的一团材料：里面有许多细胞，细胞之间还有支撑它们的物质。我们研究的“组织”，就是这样的结构。

1.1 组织和细胞分别在哪一层

层次	简单解释	例子
人体	整个生命个体	一个人
器官	多种组织共同承担一定功能的结构	心脏
组织	细胞与周围材料形成的结构	心脏中的心肌组织
细胞	人体结构和功能的基本单位	心肌细胞

所以，我们可以先记住“人体 → 器官 → 组织 → 细胞”。组织比细胞大，但组织不仅仅是细胞的简单堆积，细胞之间的材料和排列也属于组织的一部分。[1]

1.2 细胞可以想象成一个微小的工作单位

典型有核人体细胞外面有细胞膜，内部有细胞质和细胞核。细胞膜像边界；细胞质是内部许多活动发生的环境；细胞核保存着大部分 DNA。这里描述的是常见结构，人体也有成熟红细胞等例外，不需要用例外打断最初的理解。

细胞有不同分工。例如，上皮细胞构成身体表面或器官内壁等结构；免疫细胞参与防御；成纤维细胞参与组织支撑和修复。先认识这三类名字就够了，不必现在背全部细胞分类。

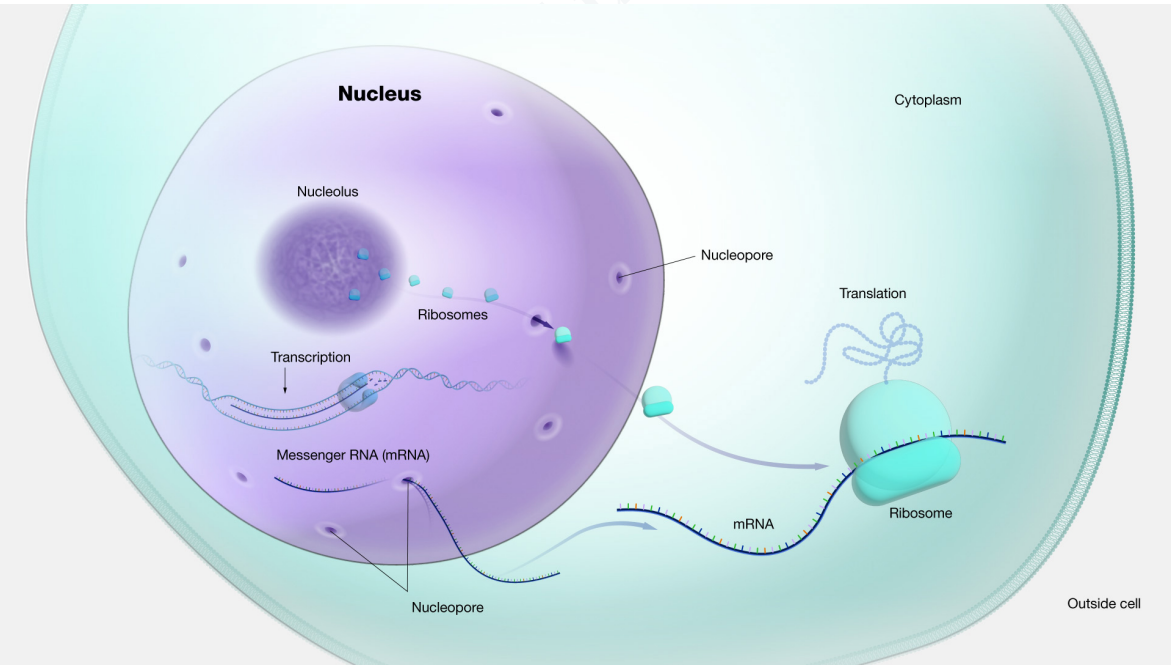
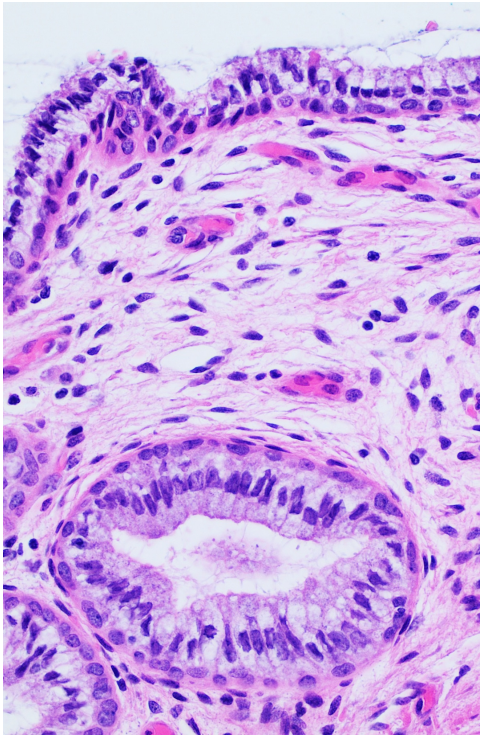


图 1 典型有核细胞的局部示意。紫色区域为细胞核（Nucleus），其外为细胞质（Cytoplasm），最外侧为细胞膜；核糖体参与蛋白质合成。先认识这些位置关系，图中的转录与翻译将在后文展开。示意颜色与尺寸用于教学，不是显微照片。

图片：NHGRI；许可：Public domain；原图等比缩放。

1.3 为什么显微镜照片还不够

照片能提供外形、排列和组织结构的线索，专家也能据此作出许多判断。但它不能直接给出所有细胞的分子状态。我们希望知道某个细胞是否在增殖、是否受到刺激，以及它属于哪类细胞；这时需要更多测量。



先看组织的排列。深紫色区域帮助观察细胞核的位置，图中还能看到表面上皮和下方的腺体结构。

再区分形态与分子测量。组织照片有助于认识结构；若要知道哪些基因在这些位置表达，还需要相应的分子测量。

图 2 真实的宫颈管组织显微图像，采用苏木精—伊红（H&E）染色。它展示了形态与排列，但不能直接给出各位置的 RNA 表达；此图不是贯穿全文肿瘤案例的样本。

图片：Mikael Häggström；许可：CC0 1.0；原图等比缩放。

回到肿瘤薄片：我们能看到一片组织，但还想知道其中哪些位置有免疫细胞。这就要进一步认识细胞里面保存和使用的信息。

本章要记住

组织里有细胞；细胞有不同分工；照片提供形态，分子测量提供另一类信息。

2 DNA 和基因究竟是什么

2.1 DNA 是保存遗传信息的分子

DNA 是一种实际存在的分子，不是抽象概念。它的结构常画成双螺旋，像扭转的梯子。DNA 的序列可用 A、T、C、G 四种字母表示；这些字母代表不同的碱基，它们的排列承载遗传信息。[2]

作为 CS 学生，我们可以把 DNA 序列先看成很长的字符串。但真实 DNA 是分子，它的包装方式和细胞中的环境也会影响信息如何被使用。字符串只是第一层表示。

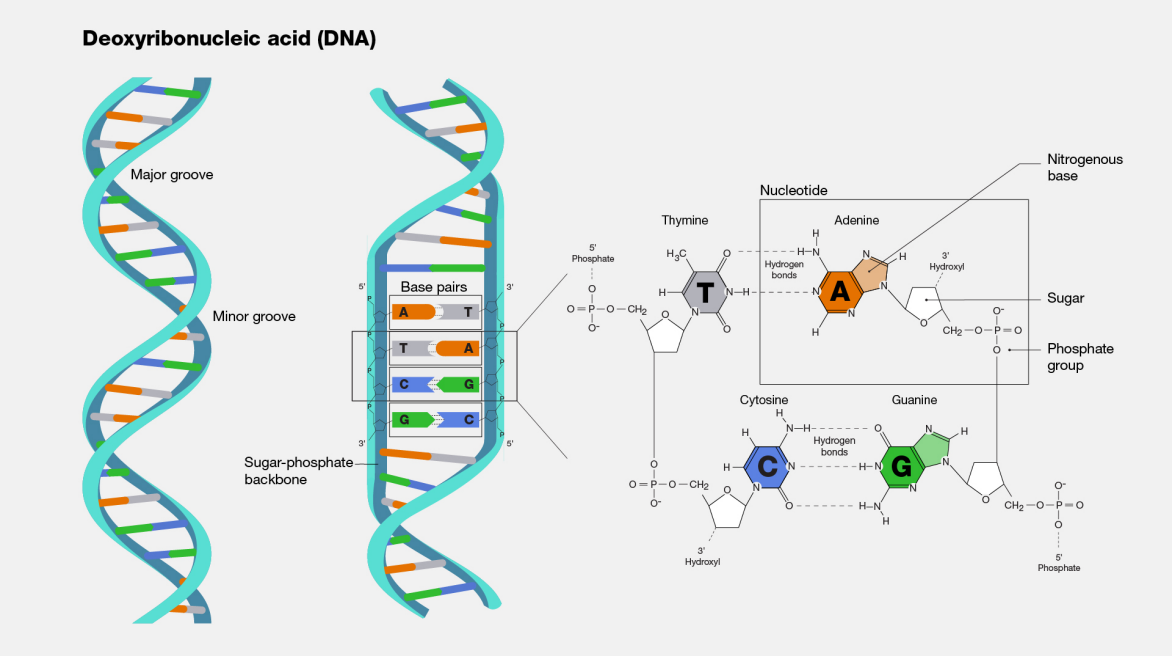


图 3 DNA 的结构与序列是两个观察视角。左侧为双螺旋，中间放大了碱基配对，右侧显示局部化学结构；A 与 T 配对，C 与 G 配对。入门时重点理解分子结构与字母序列的联系，无须记忆右侧化学细节。

图片：NHGRI；许可：Public domain；原图等比缩放。

2.2 基因是 DNA 上具有功能的一段信息

基因不是整条 DNA 的另一个名字。一个基因对应 DNA 上的特定区段，可用于产生 RNA；许多基因最终与蛋白质的制造有关，还有一些基因产生的 RNA 本身就有功能。[3]

把 DNA 类比成一本很长的说明书，基因像其中一段有具体用途的内容。DNA 上也有参与调控等作用的区域，因此不能把全部 DNA 都当成一段段蛋白质制造说明。

2.3 染色体和基因组怎么放进这张图

DNA 会与蛋白质结合，组织成染色体。可以粗略把染色体理解成 DNA 的包装形式。基因组指一套遗传信息；它与“此刻表达了什么”是两个问题。[3]

概念	我们可以先这样记	不要混淆成
DNA	保存遗传信息的分子	某一个基因
基因 Gene	DNA 上具有功能的特定区段	整套遗传信息
染色体 Chromosome	DNA 与蛋白质形成的组织结构	新的另一种信息分子
基因组 Genome	一套遗传信息	当前正在使用的信息集合

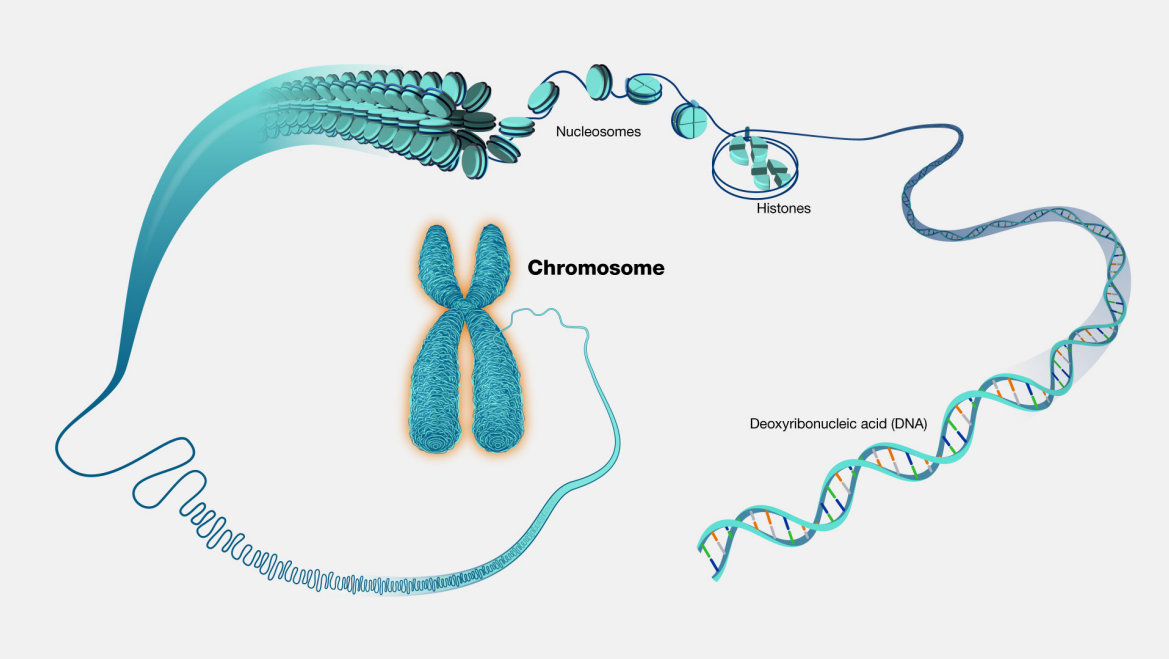


图 4 从 DNA 双螺旋到染色体的组织层次。可从右向左观察 DNA 如何与蛋白质结合并形成更高层次的包装；各部分不按统一比例绘制。图中的 X 形是特定阶段的结构示意，不表示染色体始终呈 X 形。

图片：NHGRI；许可：Public domain；原图等比缩放。

2.4 为什么不同细胞可以拥有相似 DNA

同一个人的多数有核体细胞，基因组大体相同。然而神经细胞和免疫细胞的工作明显不同。重要原因之一是：它们使用不同的基因，使用程度也不同。DNA 中“有这段信息”与细胞“现在正在使用这段信息”，需要分开。

本章要记住

基因是 DNA 的特定区段；基因存在，不代表它此刻被同样程度地使用。

3 RNA 是怎样产生的

3.1 细胞会按照 DNA 信息制造 RNA

RNA 是另一类实际存在的分子。细胞按照 DNA 中的信息合成 RNA，这个过程叫**转录**（transcription）。DNA 并不是整条变成 RNA；细胞利用相应信息生成 RNA 分子，DNA 仍然存在。[4]

继续用说明书类比：DNA 是保存的信息，RNA 可以像为当前工作制作的副本。一段基因信息可以对应多个 RNA 分子，所以 RNA 的数量会随细胞状态变化。这里的“副本”强调信息关系，不表示 DNA 和 RNA 的化学组成完全相同。

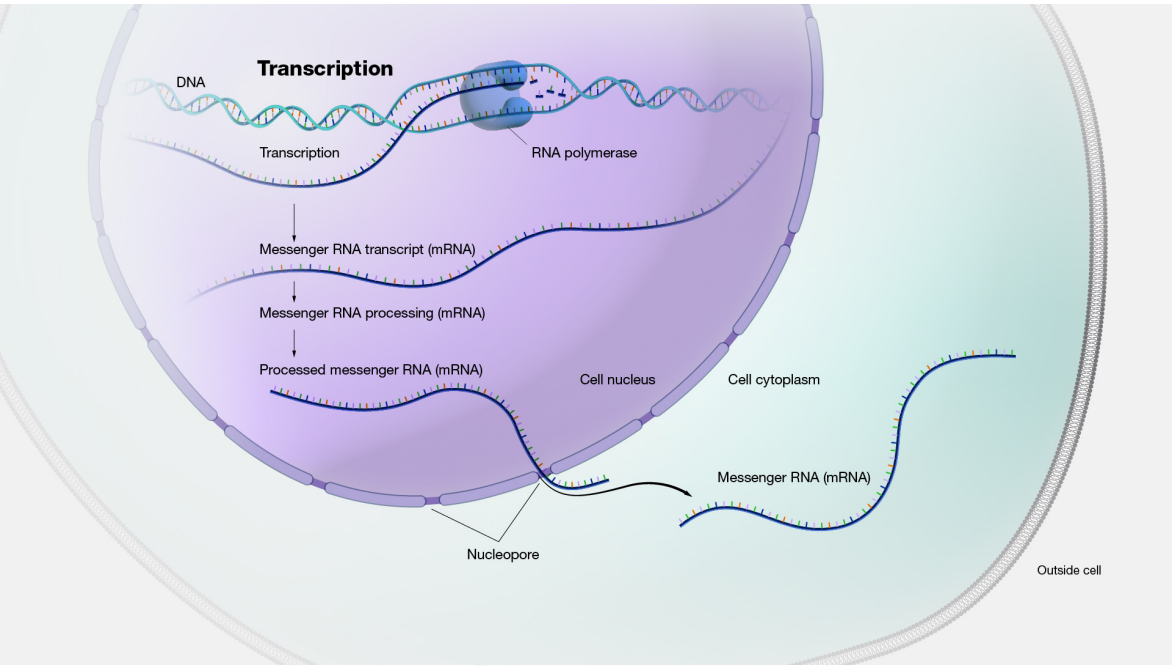


图 5 真核细胞中的转录及 mRNA 加工示意。沿图自上而下观察：RNA 聚合酶根据 DNA 模板合成 RNA，mRNA 经加工后可经核孔离开细胞核。此图展示 mRNA 的典型路线，不表示所有 RNA 都会离核或进入翻译。

图片：NHGRI；许可：Public domain；原图等比缩放。

3.2 mRNA 是 RNA 中的一种

mRNA 叫信使 RNA，它携带用于制造蛋白质的信息。RNA 还有其他类别，其中一些参与蛋白质制造的过程，另一些参与调控等功能。我们现在只需记住：**mRNA 是 RNA 的一个子类，不是所有 RNA 都是 mRNA**。[5]

3.3 RNA 为什么能提供细胞状态的线索

如果某类 RNA 在一个细胞中测得比较多，说明这个细胞在相应表达方面有一定信号。不同细胞会呈现不同的 RNA 组合；同一类细胞受到刺激后，组合也可能改变。通过这些组合，我们可以研究细胞的身份和状态。

但 RNA 水平不是“此刻产生速度”的直接读数。它同时受合成、降解及测量过程影响。我们测到的是实验所记录的 RNA 信号，再据此作解释。

3.4 先把一个常见误解排除

“DNA → RNA”表示信息通过转录被用于制造 RNA，不表示细胞把自己的 DNA 消耗掉。类似我们从文件生成多个工作副本，原文件仍然在，只是这个计算机类比忽略了许多真实分子过程。

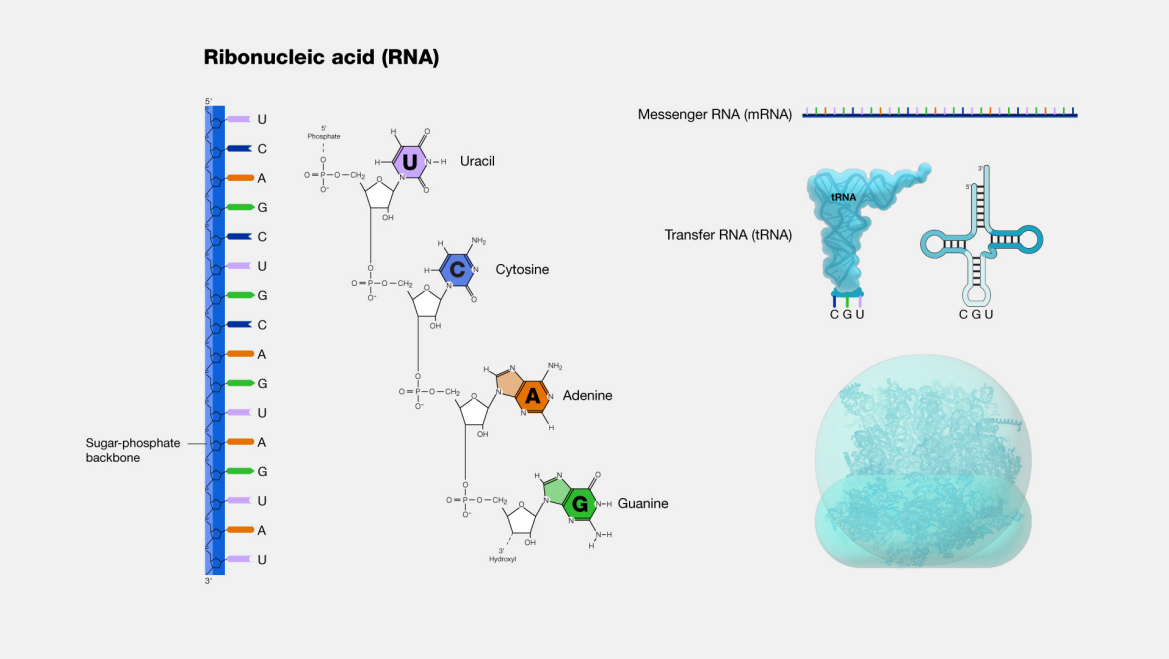


图 6 RNA 不只有 mRNA。右上方为信使 RNA（mRNA），其下展示转运 RNA（tRNA）和核糖体 RNA（rRNA）相关结构；后两者也参与蛋白质合成。RNA 可以形成复杂结构，不能把所有 RNA 都理解为等待翻译的一条直线。

图片：NHGRI；许可：Public domain；原图等比缩放。

我们想知道什么	更相关的观察
细胞拥有哪些遗传信息	DNA 或基因组信息
细胞当时有哪些 RNA 信号	RNA 或转录组信息
细胞里有哪些功能性蛋白质	蛋白质相关测量

回到我们的薄片：测 RNA 可以帮助识别免疫相关的表达特征，但并不是直接拍到了一个“免疫细胞标签”。我们后面还会解释怎样从信号推断身份。

本章要记住

转录根据 DNA 信息产生 RNA；测得的 RNA 水平为细胞身份和状态提供线索。

4 蛋白质是什么以及怎样产生

4.1 蛋白质由氨基酸链组成

蛋白质是一类分子，通常由一条或多条氨基酸链构成。把氨基酸想成不同种类的小珠子：珠子按一定顺序连起来，链再折叠成一定形状。顺序影响结构，结构与功能密切相关。[6]

单个蛋白质分子在分子尺度，肉眼看不见，普通光学显微镜通常也无法直接辨认其具体形状。但大量蛋白质构成的材料可以看见、摸到：头发富含角蛋白，肌肉含有参与收缩的蛋白质。蛋清也含有许多蛋白质，同时含大量水。

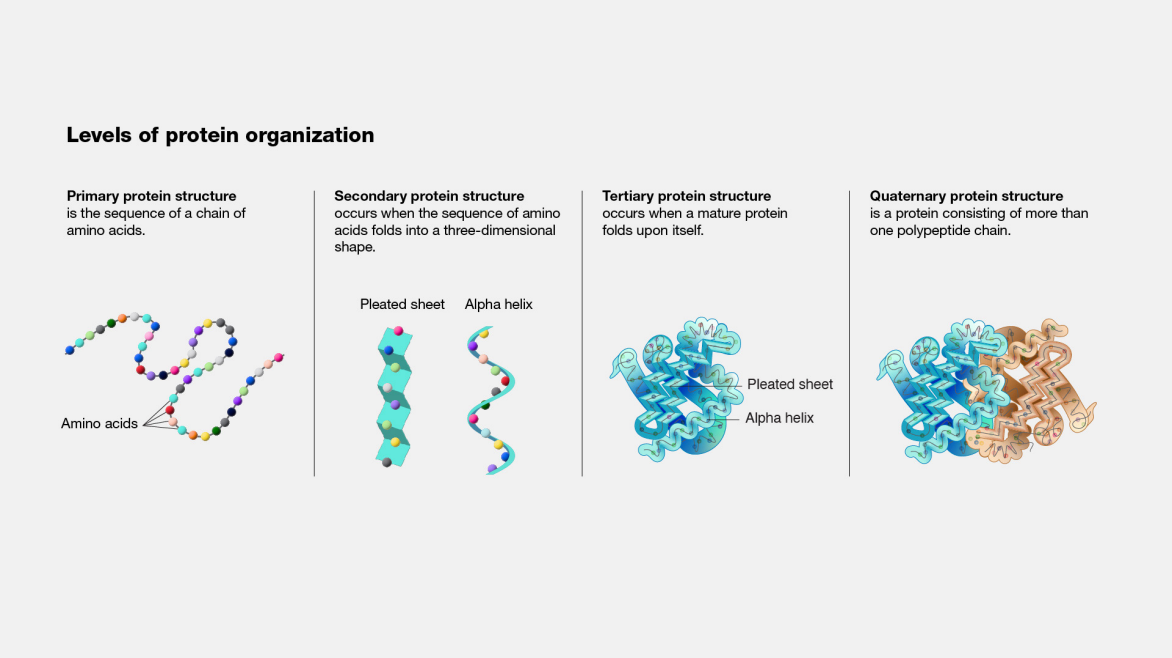


图 7 蛋白质的结构层次。从左到右依次为氨基酸序列、局部结构、整体折叠与多链组装；并非每种蛋白质都有多链组装这一层次。先理解“链具有顺序，也具有空间结构”，再将结构与功能联系起来。

图片：NHGRI；许可：Public domain；原图等比缩放。

4.2 翻译把 mRNA 的信息用于制造蛋白质

细胞中的核糖体等分子机器读取 mRNA 的信息，将氨基酸按相应顺序连接起来。这个过程叫**翻译**（translation）。这里的“翻译”是分子生物学术语，和自然语言翻译是不同任务。[7]

4.3 为什么蛋白质重要

许多具体工作由蛋白质承担：酶帮助化学反应进行，血红蛋白运输氧气，抗体参与防御，受体接收信号。受体可以先理解为细胞识别某些外来分子信号的组件。

本章要记住

DNA 保存信息；转录产生 RNA；其中的 mRNA 可被翻译成蛋白质；蛋白质承担许多实际功能。

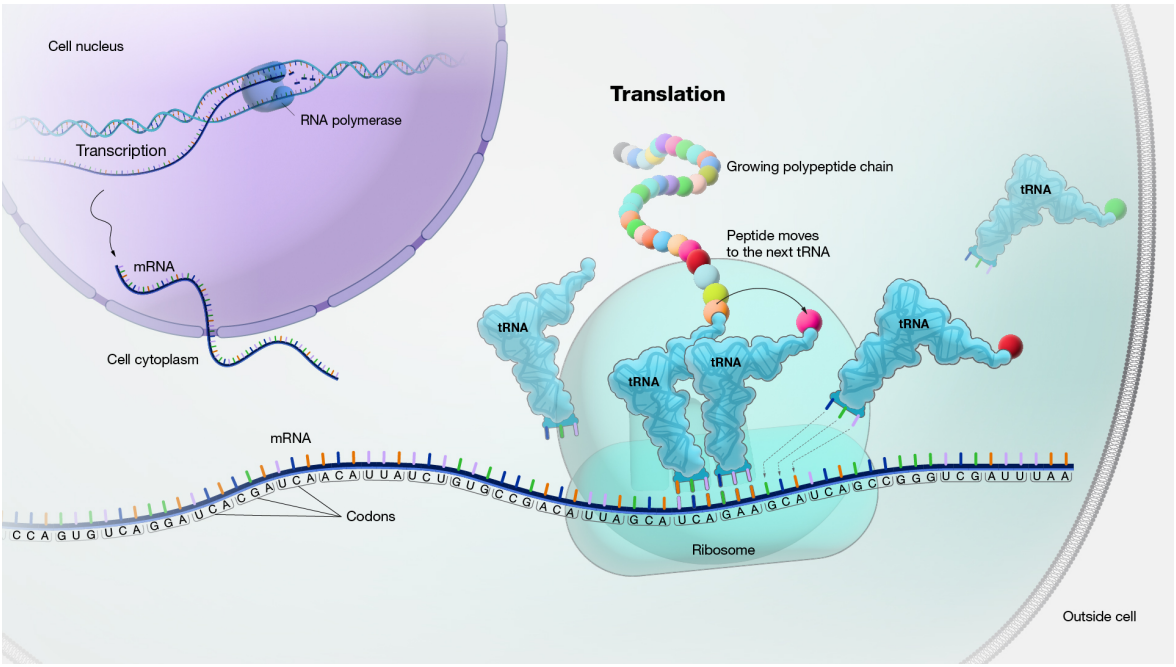


图 8 翻译过程示意。下方长链为 mRNA，蓝绿色结构为核糖体，正在延长的彩色小球串代表多肽链；tRNA 参与运送相应的氨基酸。RNA 提供编码信息，氨基酸构成多肽链，不能把翻译理解为 RNA 本身变成蛋白质。

图片：NHGRI；许可：Public domain；原图等比缩放。

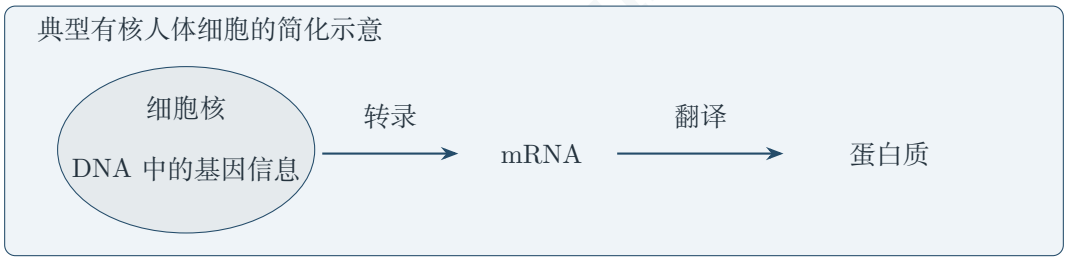
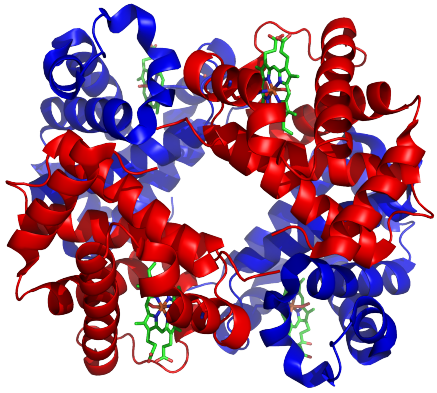


图 9 信息关系示意，不按实际尺寸绘制。mRNA 在核内产生，参与蛋白质制造前通常需要加工并转运；图中省略这些步骤。部分 RNA 本身有功能，不进入翻译路线。



把功能名词与具体结构联系起来。血红蛋白是上文运输氧气的例子，这里可以看到蛋白质的空间结构。

再回到测量层次。RNA 提供表达线索；若要判断蛋白质含量或功能是否发生变化，仍需相应证据。

图 10 血红蛋白的三维结构模型，由 PDB 1GZX 的结构数据绘制，飘带帮助展示蛋白链的折叠。模型不是显微照片，绘图颜色也不是分子的真实颜色；它不能给出组织中的蛋白质含量。

图片：Richard Wheeler (Zephyris)；许可：CC BY-SA 3.0；原图等比缩放。

5 基因表达是在说什么

5.1 表达表示基因信息被用于产生功能产物

基因表达（gene expression），是基因信息被用于产生 RNA 或蛋白质等功能产物的过程。研究 RNA 数据时，“某基因表达高”通常表示与这个基因相关的 RNA 信号测得较多。[8]

例如，细胞甲和细胞乙都拥有某个基因，但在相同测量条件下，甲记录到更多对应 RNA。我们会说甲的这个基因表达较高。它并不表示甲拥有更多个基因，也不表示 DNA 序列变长了。

5.2 为什么相似 DNA 能产生不同细胞

细胞并不会同样程度地使用所有基因。不同的表达组合与细胞不同的结构、功能和状态有关。可以把它理解成：员工拥有相似的说明书，但当前执行的任务不同，生成的工作副本也不同。

5.3 细胞类型和细胞状态要分开

细胞类型（cell type）是较稳定的身份，例如免疫细胞中的 T 细胞；**细胞状态**（cell state）是当下的活动情况，例如应对刺激或正在增殖。增殖就是细胞分裂、数量增加相关的过程。

同一种类型可以有不同状态，不同类型也可能共享一种状态。例如，多个类型都可能处于增殖状态。算法把细胞分成两组后，需要判断分组反映的是身份、状态，还是实验差异。

5.4 标志基因怎样帮助识别细胞

某些基因的表达常为识别细胞身份或状态提供线索，我们称它们为**标志基因**（marker gene）。科研人员通常结合多个标志、已有研究和组织背景判断，而不是看到一个基因较高就给出确定标签。

5.5 RNA 多为什么不一定等于蛋白质多

从 RNA 到蛋白质，中间还有翻译效率和蛋白质降解等过程。测 RNA 是一个观测层次，测蛋白质是另一个观测层次。RNA 数据可以提出功能相关假设，但不自动证明蛋白质数量或功能强度发生了相同变化。

理解检查

基因是信息区段，表达是信息被使用；细胞类型是身份，细胞状态是当下情况。空间转录组主要提供 RNA 层面的表达线索。请试着解释：两个细胞拥有相似的 DNA，为什么仍可能表现出不同的功能？

第二部分

测量原理与空间信息

第 6–9 章：从 RNA 集合到带位置的实验读数

这一部分要理解什么

理解转录组测量的范围和局限，比较混合组织、单细胞与空间测量。弄清一个测量单位代表什么，以及条形码、UMI 和成像怎样把 RNA 信号与位置关联起来。

Auutuumn

6 转录组是很多 RNA 的整体情况

6.1 先理解为什么要加一个“组”字

只测一个基因，可以看到一个信号；同时测很多基因，才能看到整体的表达组合。**转录组**（transcriptome）指一个细胞或组织在特定条件下的 RNA 集合。[9]

我们可以把它理解为一份“当时的 RNA 情况表”。它与基因组不同：基因组主要描述保存的遗传信息，转录组描述当时存在的 RNA。细胞的环境或状态改变时，转录组也可能变化。

6.2 一个基因和一个 RNA 分子不是一一对应

一个基因可以产生很多 RNA 分子。一个基因也可能产生不同的**转录本**（transcript）。这里的转录本可以先理解为 RNA 产物；谈“转录本种类”时，也可能在区分同一基因产生的不同版本。

在常见入门分析中，研究人员会把与同一基因有关的信号汇总到基因层面。因此表达表的一列常是一个基因，数值反映该基因相关信号，而不是说“每个基因只有一个 RNA”。

6.3 测转录组不等于测到了所有 RNA

真实实验存在捕获效率、测序投入和技术覆盖范围的限制。有些方案关注较广的转录组，有些只检测预先选定的一组基因。这组目标叫 **panel**（基因面板），可以先理解为实验事先决定的“测量名单”。

因此，数据里没看到某个 RNA 信号，不能直接说细胞完全没有它。尤其某个基因根本不在测量名单中时，它属于没有观测，不能当成确定的零表达。

对 CS / AI 读者来说，这里要区分两种情况：“测了这个特征但读数为零”，以及“实验根本没有测这个特征”。即使文件里都能用零填充，它们的含义也不相同。

6.4 RNA 测量怎样帮助研究组织

假设免疫相关的一组基因在某些区域更明显，研究人员就有理由进一步检查这些区域是否含有免疫细胞。表达模式提供线索，已有参考和额外验证帮助判断线索是否可靠。

我们还没有加入空间。下一步先看看：如果同样测 RNA，但把细胞合在一起或分开测，会得到哪些不同信息。

本章要记住

转录组是一组 RNA 的整体情况；表达数据是对它的不完整测量。

7 混在一起测和分开测有什么区别

7.1 第一种方式是测一份混合组织

如果把一块组织中的 RNA 汇总来测，我们得到整份样本的总体表达情况。这类方法常叫 **bulk RNA-seq**，bulk（批量）可以先理解为“混合在一起”。RNA-seq 指通过测序来研究 RNA。[10]

它像把公司的工作记录全部汇总：我们能知道整个公司用了哪些任务信息，但很难区分每条记录来自哪个员工。某个信号变多，可能是相关员工变多，也可能是每个人的活动更强。

7.2 第二种方式是尽量分别测每个细胞

单细胞 RNA 测序，简称 **scRNA-seq**（sc：single-cell），尽量把不同细胞的 RNA 信号分开记录。于是可以比较不同细胞，发现它们有哪些身份和状态差异。常见实验需要将细胞从组织中**解离**，也就是从原来的结构里分离出来。

这像分别保存每个员工的工作记录，但通常丢失了他们原来的座位。并非所有细胞都能成功进入数据，一次记录也可能混入多个细胞，所以仍然需要质量检查。

研究方式	得到什么	暂时看不到什么
混合组织测量	整份组织的总体表达	每种细胞各自贡献多少
单细胞测量	分别记录细胞间的表达差异	常规解离后细胞原来的组织位置

7.3 单细胞核又是什么

一些实验分离并测量细胞核，称为**单细胞核 RNA 测序**，简称 **snRNA-seq**。细胞核是细胞的一部分，因此核内 RNA 与整个细胞 RNA 的构成不完全相同。现在只需知道：single-cell 和 single-nucleus 不是完全相同的测量对象。

7.4 我们的研究问题还缺什么

对肿瘤薄片，即使知道存在多少种免疫细胞，我们仍想知道它们在内部还是边缘、与哪些细胞相邻。仅有总体表达或失去原位坐标的单细胞表，都不能直接完整回答这个布局问题。

本章要记住

bulk 看总体，单细胞看个体差异；想研究组织布局，还要保留位置。

8 空间转录组把表达放回组织地图

8.1 空间转录组同时关联表达和位置

空间转录组学（spatial transcriptomics），是在保留空间位置关联的条件下测量组织中的 RNA 表达。它让我们研究“哪些表达信号出现在哪里”，以及这些位置之间的关系。[11]

把公司类比补完整：我们有员工的工作记录，也保留座位图。研究对象由一份没有布局的信息表，变成了一张具有表达信息的组织地图。



图 11 空间数据的真实可视化示例，来自 Squidpy 官方 Visium 教程。左图用连续颜色表示 Sox8 表达信号（表达量），右图用离散颜色显示分群及注释标签（属于哪个空间），两图使用同一组织的空间位置。圆点代表测量位置，不自动等于单个细胞；注释标签包含分析与解释，并非实验直接读出的身份。

图片：Squidpy / Theis Lab / scverse；许可：BSD 3-Clause；原图等比缩放。

8.2 为什么位置有生物学意义

组织的功能依赖细胞的排列与局部环境。免疫细胞集中在肿瘤边缘或出现在内部，是两个不同的观察；脑组织不同结构层的表达模式，也可能不同。位置帮助研究人员提出更具体的问题，但布局本身不直接证明某个功能或因果关系。

8.3 空间不意味着每一行都是一个细胞

不同技术的测量单位不同。有些数据对应分割得到的细胞，有些对应一个捕获区域。捕获区域常叫 **spot**，我们可以先把它想成组织上的一个小圆圈或小区域，里面可能有多个细胞。

较细的网格也可能被合并成 **bin**，即一个用于分析的网格区域。无论它多小，网格边界都不自动等于细胞边界。一份数据到底是在测细胞、spot 还是 bin，要看实验和后续处理。

一行对应的对象	我们能直接说什么	我们还不能直接说什么
分割得到的细胞	该细胞区域记录到的 RNA	分割及分子归属完全正确
多细胞 spot	该区域的混合 RNA 信号	每个细胞分别表达多少
合并网格 bin	该网格区域的 RNA 信号	这个网格就是一个完整细胞

常见实验测量一张二维组织切片。二维坐标保留切片中的位置，不能直接代表完整器官的三维结构。研究三维组织时，通常还需要多个切片或其他信息。

本章要记住

转录组提供 RNA 表达信息，空间保留这些信息在组织中的位置；分析前先确认一个观测位置究竟代表什么。

9 实验怎样知道哪些 RNA 来自哪里

9.1 先看一种典型的测序路线

下面以捕获 RNA 的空间条形码方案为例。研究人员准备一张载体，上面不同捕获位置带有不同的条形码序列。**条形码**（barcode）可以先理解成位置标签；实验知道每个标签对应哪个位置。

将组织薄片放在载体上，捕获到的 RNA 经实验处理获得相关标签，再进行测序。测序仪读到的序列片段叫 **read**。计算流程识别标签以及目标基因，便能把分子信号关联回位置。2016 年的经典空间转录组工作采用了这一类思路。[11]

9.2 一份读数要回答两个问题

问题	帮助回答的信息	通俗理解
来自哪里	空间条形码和对应坐标	包裹上的地址标签
属于哪个目标	RNA 对应的序列或探针信息	包裹内容的识别线索

实验常将 RNA 的信息转换到适合建库和测序的 DNA 产物上，再测序；这不改变我们研究的对象是 RNA 表达。这里省略实验化学细节，但要避免把“测序仪读到 DNA 产物”误解为“正在研究基因组突变”。[10]

这里的**建库**，可以先理解为把分子处理成测序仪可以读取的一组材料；它不是建立计算机数据库。

9.3 为什么多个 reads 不一定等于多个 RNA

建库中的扩增可能让一个原始分子产生多个副本，因此多个 reads 可能来源（比如经过 PCR 扩增）。部分方案加入 **UMI**（unique molecular identifier，独特分子标识符），帮助识别重复来源。可以把空间条形码理解为“位置标签”，把 UMI 理解为“分子去重线索”。[12]

例如，在同一位置、同一基因下，若若干 reads 具有相同的 UMI，流程可能把它们合并为一个分子来源的计数。真实去重还涉及序列错误等问题，因此这个例子只说明“reads 数量”和“去重后的分子计数”为何可能不同。

9.4 另一条路线是直接在组织里成像

成像型方法使用探针等分子工具识别目标，并通过显微成像及多轮识别等过程定位 RNA。**探针**可以先理解为实验中识别特定目标的工具。它可能输出“某种 RNA 在坐标哪里”的分子表，再聚合到细胞或区域。[13]

本章要记住

先理解两条思路：通过标签保留位置，或通过成像定位分子。不同方案能检测什么、测得多细、测得多完整，会影响后续计算问题。现在不用背平台名。

第三部分

计算分析与科研实践

第 10–15 章：从表达矩阵到可信科学结论

这一部分要理解什么

把实验读数转成矩阵、坐标与图像，理解常见分析步骤及算法任务。沿着肿瘤切片的例子，分清测量、推断、比较和验证，学习判断模型输出能支持怎样的结论。

Auutuumn

10 从 RNA 读数到基因表达矩阵

上一章，我们了解了实验如何识别 RNA 来自哪个位置、属于哪个基因。接下来需要解决一个问题：**如何把这些 RNA 信号整理成计算机可以分析的数据？**

答案就是将它们整理成一张矩阵。在空间转录组研究中，这张矩阵叫作**基因表达矩阵**（gene expression matrix）。

10.1 把 RNA 信号整理成一张表

假设我们有一张组织切片，其中包含四个捕获位置（spot），分别记为 P1、P2、P3 和 P4。

实验完成后，我们统计每个位置检测到了多少与不同基因对应的 RNA 信号，就可以得到下面这张表：

位置	基因 A	基因 B	基因 C
P1	30	2	5
P2	27	3	8
P3	3	28	4
P4	16	17	6

例如，P1 中基因 A 的计数为 30，基因 B 为 2，基因 C 为 5。这说明在 P1 位置，实验检测到的基因 A 表达信号比另外两个基因更丰富。

这里的数字只是教学示例。真实数据中的基因通常使用具体名称或 ID，例如 EPCAM、PTPRC 等。不同基因的表达可以为判断细胞类型提供线索，但通常需要结合多个标志基因，而不能只依赖某一个基因。

10.2 从 CS 的角度理解这张矩阵

对于 CS 学生来说，基因表达矩阵其实就是一张熟悉的**特征矩阵（Feature Matrix）**。

我们可以这样理解：

- **每一行是一个样本**：在空间转录组中，通常对应一个 spot；在单细胞数据中，则可能对应一个 cell。
- **每一列是一个特征**：这里的特征就是基因。
- **每个数值是表达计数**：表示实验在该位置记录到了多少与对应基因相关的 RNA 分子信号。

例如，P1 可以表示为一个三维特征向量：

$$X_1 = [30, 2, 5]$$

P2、P3 和 P4 也各自对应一个向量。把这些向量按行排列起来，就得到了完整的表达矩阵：

$$X = \begin{bmatrix} 30 & 2 & 5 \\ 27 & 3 & 8 \\ 3 & 28 & 4 \\ 16 & 17 & 6 \end{bmatrix}$$

在实际研究中，基因数量可能达到几千甚至几万个，因此每个 spot 对应的就是一个高维特征向量。

数学上，原始计数矩阵通常表示为：

$$X \in \mathbb{N}_0^{N \times G}$$

其中，N 表示观测单位（spot 或 cell）的数量，G 表示基因数量，$\mathbb{N}_0$ 表示包含零的非负整数集合。

矩阵中的元素 X_{ig} 表示第 i 个观测单位中，第 g 个基因的记录计数。

需要注意，**表达计数不是基因的数量**。例如，P1 中基因 A 的计数为 30，并不是说 P1 有 30 个基因 A，而是实验记录到了与基因 A 对应的 RNA 表达信号。由于捕获效率、测序误差等因素，这个数字也不一定等于真实存在的 RNA 分子数量。

另外，原始计数矩阵通常还需要经过归一化、对数变换等预处理。处理后的数值可能是小数，某些标准化表示中甚至会出现负数，因此一般可以写作：

$$X \in \mathbb{R}^{N \times G}$$

所以，拿到一份表达矩阵时，首先要确认它保存的是原始计数，还是已经处理过的表达值。本文后续统一采用“观测单位 × 基因”的矩阵结构。

10.3 如何从矩阵中观察表达模式

有了基因表达矩阵，我们就可以开始比较不同位置的基因表达特征。

回到最开始的例子：

- **P1 和 P2**：基因 A 的表达计数较高，基因 B 较低，因此两者的表达模式比较相似。
- **P3**：基因 B 的表达计数较高，和 P1、P2 呈现出不同的表达模式。
- **P4**：基因 A 和 B 都有较高的表达计数，说明这个位置同时检测到了两种表达信号。

假设基因 A 是上皮细胞的标志基因，基因 B 是免疫细胞的标志基因，那么我们可能会猜测：P1、P2 更接近上皮细胞相关区域，而 P3 可能具有免疫细胞相关特征。

但是，P4 同时表达 A 和 B，是否说明一个细胞同时具有上皮细胞和免疫细胞两种身份？

不能直接这样判断。

因为一个 spot 不一定只包含一个细胞。例如，P4 可能同时覆盖了上皮细胞和免疫细胞，测量结果实际上混合了多个细胞的 RNA 信号。

即使 P4 对应单个细胞，也需要考虑真实的基因共表达、背景污染或细胞分割误差等可能性。

因此，**基因表达矩阵能够帮助我们发现表达模式，但不能仅凭几个基因的表达值，就直接确定细胞类型**。

10.4 矩阵里的零意味着什么

最后还有一个很容易产生误解的地方：如果某个基因的表达计数为 0，是不是说明这个位置完全没有表达该基因？

答案是不一定。

在空间转录组实验中，RNA 的捕获和测序并不是百分之百准确的。即使某个基因确实发生了表达，也可能因为表达量太低、捕获效率有限或测序深度不足，最终没有被记录下来。此，表达矩阵中的零，首先表示**实验没有检测到对应的表达信号**，而不一定表示该基因在生物学上完全没有表达。

这也是为什么在后续的数据预处理和建模中，我们需要谨慎处理零值：不能把所有零都当作真实的无表达，也不能认为所有零都是需要补齐的缺失数据。

11 坐标、图像和文件怎样与矩阵对应

上一章，我们已经把 RNA 测序得到的信号整理成了基因表达矩阵。矩阵的每一行对应一个 spot（空间捕获位置），每一列对应一个基因，其中的数值表示该位置检测到的基因表达信号。

但这里还有一个问题：**我们知道每个 spot 表达了哪些基因，却还不知道这些 spot 在真实组织中分别位于哪里**。

因此，空间转录组数据通常不只有基因表达矩阵，还需要保存空间坐标，有时还会包含组织图像。这几类数据结合起来，才能帮助我们理解基因表达与组织空间结构之间的关系。

11.1 表达矩阵之外还要有坐标

继续使用上一章的四个位置 P1、P2、P3 和 P4。

假设我们已经得到它们的基因表达矩阵，现在再为每个位置记录一个二维坐标：

$$P1 = (0,0), \quad P2 = (1,0), \quad P3 = (0,1), \quad P4 = (1,1).$$

这样，我们就有了两张相互关联的表：

- **基因表达表**：记录每个 spot 中各个基因的表达情况。
- **空间坐标表**：记录每个 spot 在组织中的位置。

例如，基因表达表告诉我们 P1 中基因 A 的计数为 30；空间坐标表则告诉我们 P1 位于 $(0,0)$。将两者结合，就能知道某个基因在组织的什么位置表达较高。

从 CS 的角度看，这类似于数据库中的两张表：一张保存特征，另一张保存坐标，通过共同的 spot ID 进行关联。

用数学语言表示，基因表达矩阵为

$$X \in \mathbb{R}^{N \times G},$$

其中 N 是观测位置数，G 是基因数。

对应的空间坐标矩阵为

$$S \in \mathbb{R}^{N \times 2},$$

其中每一行保存一个位置的 (x, y) 坐标。

这里最重要的是：X 和 S 的同一行，必须对应同一个 spot。

例如，如果 X 的第一行是 P1 的基因表达，那么 S 的第一行也必须是 P1 的坐标。实际处理数据时，应根据 spot ID 检查对应关系，不能仅凭两个矩阵的行数相同，就认为它们已经正确对齐。

11.2 表达相似和位置相邻是两种关系

有了基因表达矩阵和空间坐标，我们就能从两个不同的角度分析 spot 之间的关系。

第一种是**表达相似性（Expression Similarity）**，也就是两个 spot 的基因表达模式是否相似。

例如：

- P1 的表达向量为 $[30, 2, 5]$；
- P2 的表达向量为 $[27, 3, 8]$；

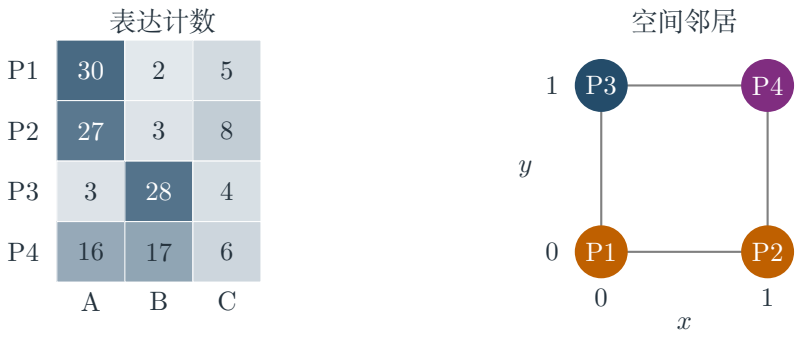


图 12 基因表达与空间坐标的对应关系。左侧是四个 spot 的基因表达矩阵，右侧是这些 spot 在二维空间中的位置。连线表示横向或纵向相邻。颜色仅用于辅助区分表达特征，不代表已经确认的细胞类型。

- P3 的表达向量为 $[3, 28, 4]$。

可以直观地看出，P1 和 P2 的表达模式比较接近：它们的基因 A 表达较高，基因 B 表达较低。而 P3 的表达模式明显不同。

在实际分析中，我们可以利用欧氏距离、余弦相似度等方法，衡量经过适当预处理后的基因表达向量之间的相似程度。表达特征接近的 spot，可以称为**表达邻居**（expression neighbors，根据基因表达特征的相似性确定的邻居）。

第二种是**空间邻近性（Spatial Proximity）**，也就是两个 spot 在真实组织中的物理距离是否接近。

例如，在图 12 中，P1 与 P2、P3 都在空间上相邻。我们可以根据坐标计算距离，也可以使用 K 近邻（KNN）或距离阈值来构建空间邻居关系。

这里需要注意一个重要区别：

空间上相邻，不代表基因表达一定相似；基因表达相似，也不代表空间位置一定接近。

例如，P1 和 P3 虽然空间相邻，但它们的基因表达模式差异很大。这可能意味着它们处于不同的组织区域，也可能反映局部细胞组成或生物学状态的差异。

从机器学习的角度理解，我们实际上获得了两种不同的关系：

- **空间关系**：根据坐标寻找邻居，关注组织结构。
- **表达关系**：根据基因表达特征寻找邻居，关注分子特征。

在后续空间转录组分析中，这两种关系可以用于构建不同的图结构，并通过图神经网络（GNN）等方法进行建模。

11.3 组织图像是第三类信息

到目前为止，我们已经有了基因表达矩阵 X 和空间坐标 S。

但这两类数据仍然不能完整描述真实组织的形态结构。

例如，即使知道某个 spot 的坐标是 $(100, 200)$，我们也无法仅凭这个坐标判断：它位于肿瘤中心、组织边缘，还是某种特殊的组织区域。

因此，部分空间转录组技术还会提供对应的组织显微图像，例如经过 H&E 染色的组织切片图像。

组织图像能够提供细胞形态、组织边界和局部结构等信息。将基因表达数据叠加到组织图像上，就可以进一步分析哪些基因在特定组织区域表达较高。

不过，要想把表达数据正确画到组织图像上，还需要解决一个问题：**坐标对齐**。

例如，组织图像的尺寸可能是 1000×1000 像素，而空间坐标使用的是另一套坐标系。如果直接使用这些坐标，表达信号可能被画到错误的位置。

将不同坐标系之间的对应关系建立起来，称为**配准**（registration，将不同图像或空间数据对齐到同一坐标系的过程）。

配准过程中可能涉及缩放、平移、旋转，有时还需要考虑组织形变。

从 CS 的角度看，这与计算机视觉中的图像配准和坐标变换非常相似。

还要注意，图像中的像素坐标和组织中的物理距离（通常以微米 μm 为单位）并不是同一个概念，使用之前需要确认坐标单位及其变换关系。

因此，我们可以把空间转录组中的三类信息总结为：

- **基因表达矩阵**：回答“这里表达了哪些基因?”
- **空间坐标**：回答“这些表达信号来自哪里?”
- **组织图像**：回答“这些位置对应怎样的组织形态?”

三者结合，才能更全面地研究基因表达与组织结构之间的关系。

11.4 AnnData 和 H5AD：如何把这些数据保存在一起

前面介绍了基因表达矩阵、空间坐标和组织图像。实际研究中，这些信息通常需要关联保存，否则处理和分析起来会非常麻烦。

在 Python 生物信息学工具生态中，一种常用的数据结构是 **AnnData**（Annotated Data，能够同时保存数据矩阵及其相关注释信息的对象）。

它可以理解为一个专门用于生物数据分析的结构化数据容器，其中不仅有基因表达矩阵，还可以保存 spot 信息、基因信息、空间坐标等内容。

AnnData 是 Python 中的数据对象，H5AD 则是这种对象常用的磁盘文件格式。

可以把它类比为：Pandas 中的 DataFrame 是数据对象，而 CSV 或 Parquet 是将数据保存到磁盘的文件格式。但 AnnData 的功能更加丰富，因为它能够管理多种相互关联的数据。

AnnData 中常见的字段如下：

字段	含义及常见用途
`X`	基因表达矩阵，通常为 spot（或 cell）× 基因。每一行对应一个观测单位，每一列对应一个基因。
`obs`	观测单位的元数据。例如 spot ID、样本来源、质量控制指标和细胞类型注释等。
`var`	基因的元数据。例如基因名称、基因 ID 和其他基因相关信息。
`obsm`	与观测单位对应的附加数组。例如 `obsm['spatial']` 通常保存空间坐标，也可以保存 PCA、UMAP 等低维表示。
`layers`	与 `X` 具有相同行列结构的其他表达矩阵。例如可以分别保存原始计数、归一化数据等不同版本。

例如，假设我们有一份包含 704 个 spot、16,562 个基因的 H5AD 数据：

- `X.shape = (704, 16562)`：表示有 704 个 spot，每个 spot 对应 16,562 个基因的表达值。
- `obs`：保存这 704 个 spot 各自的注释信息。
- `var`：保存 16,562 个基因的相关信息。
- `obsm['spatial'].shape = (704, 2)`：表示每个 spot 都对应一个二维空间坐标。

在 Python 中，可以使用 `scanpy` 读取文件并查看这些信息：

```
import scanpy as sc

adata = sc.read_h5ad("sample.h5ad")

print(adata.shape)
print(adata.X.shape)
print(adata.obs.head())
print(adata.var.head())

if "spatial" in adata.obsm:
    print(adata.obsm["spatial"][:5])
```

需要特别注意：**H5AD 只是一种数据保存格式，并不意味着文件中的数据已经完成质量控制或标准化**。

例如，`X` 中保存的可能是原始 RNA 计数，也可能是已经归一化、对数变换后的表达值。

同样，字段名中出现 `raw` 或 `counts`，也不能单凭名称保证其中一定保存了未经处理的原始计数。

在分析数据前，应结合数据集说明、处理流程和实际数值确认数据状态。[14]

本章要记住

空间转录组数据不只是一张基因表达矩阵。它通常以 spot 或 cell 为观测单位，把基因表达、空间坐标和各种注释关联起来；部分数据还提供组织图像。

从 CS 的角度看，表达矩阵提供特征，空间坐标提供位置关系，组织图像提供形态信息，而 AnnData/H5AD 则负责组织和保存这些数据。

理解这套结构后，就可以进一步研究空间邻居构建、图神经网络建模以及空间转录组的多模态分析。

12 空间转录组数据的常见分析流程

前面我们已经知道，空间转录组数据可以表示为基因表达矩阵：每一行对应一个 spot 或 cell，每一列对应一个基因。

但拿到这张矩阵，并不意味着我们就能直接开展生物学分析。因为实验数据可能存在测量误差，不同位置的测序总量也可能相差很大。

因此，研究人员通常需要经过一系列处理，才能从原始数据中发现有意义的表达模式。

12.1 质量控制：先检查数据是否可靠

第一步通常是**质量控制**（Quality Control，QC），也就是检查哪些 spot 或 cell 的数据可能存在问题。

例如，某个 spot 的 RNA 总计数特别低，可能是因为它没有覆盖到足够的组织，也可能是因为该区域本来就只有少量细胞。

因此，**低计数不一定等于低质量**，还需要结合组织图像、测序平台和实验背景进行判断。

对于原始计数矩阵，我们可以先计算每个 spot 的总计数：

$$L_i = \sum_{g=1}^{G} X_{ig}$$

其中，X_{ig} 表示第 i 个 spot 中第 g 个基因的表达计数，G 是基因总数。

例如，一个 spot 的表达向量为 $[30, 2, 5]$，那么它的总计数就是：

$$L_i = 30 + 2 + 5 = 37$$

总计数越高，说明实验在该位置记录到的 RNA 信号越多。但这可能是因为细胞数量更多、RNA 含量更高，也可能是捕获效率不同，不能简单地将其理解为细胞活性更强。

实际分析时，还会结合检测到的基因数量等其他质量指标，决定是否过滤某些观测。

12.2 归一化：让不同位置的表达值更容易比较

完成质量控制后，还需要解决一个问题：**不同 spot 的总计数可能相差很大，直接比较原始数值未必公平**。

例如，P1 的总计数为 100，P2 的总计数为 1000。

如果某个基因在 P1 中计数为 10，在 P2 中计数为 100，直接看数字会觉得 P2 的表达高得多。

但实际上，这个基因在两个位置都占各自总计数的 10%。它们的差异可能主要来自测量总量不同，而不一定是该基因真实表达比例不同。

因此，我们通常使用**归一化**（Normalization，调整数据尺度，使不同观测之间更具有可比性）。

一种常见方法是先将每个 spot 的总计数缩放到统一尺度：

$$\widetilde{X}_{ig} = \frac{X_{ig}}{L_i}\, c$$

其中，L_i 是该 spot 的总计数，c 是统一选择的缩放常数，例如 10^4。

之后，还可能进行对数变换：

$$Z_{ig} = \log(1 + \widetilde{X}_{ig})$$

这种操作通常称为 `log1p` 变换，它可以压缩特别大的表达值，减小不同数值之间的尺度差异。[15]

需要注意，归一化只能缓解部分技术差异，不能恢复实验中未捕获到的 RNA，也不保证消除所有测量误差。总计数为零的观测需要单独处理。

另外，**不是所有模型都需要相同的预处理方式**。有些模型要求输入原始计数，有些则使用归一化后的表达值，应以具体方法的要求为准。

12.3 特征选择与降维：从大量基因中寻找主要差异

真实的空间转录组数据通常包含几千到几万个基因。

从机器学习的角度看，每个 spot 都是一个高维特征向量。但并不是所有基因都能提供同样多的区分信息。

因此，研究人员通常会先选择一部分具有代表性的基因，例如**高变基因**（Highly Variable Genes，HVG，在观测单位之间表现出较强变异特征的基因）。

高变基因能够帮助我们捕捉不同 spot 之间的表达差异，但它们不一定就是生物学上最重要的基因，更不能直接等同于致病基因。

接下来可以进行**降维**（Dimensionality Reduction，将高维数据转换为较低维的表示，尽可能保留重要信息）。

例如，原本每个 spot 有 10,000 个基因特征，我们可以通过主成分分析（PCA）将其表示为几十个综合特征。

这样既能减少计算开销，也有助于提取主要的表达变化模式。

需要注意，降维后的特征通常不再直接对应某个具体基因，而是多个基因信息的组合。

12.4 聚类与注释：从表达模式理解细胞类型

完成预处理和特征提取后，我们就可以尝试分析不同 spot 之间的关系。

首先是**聚类**（Clustering，根据数据特征的相似性，将观测单位划分为不同群体）。

例如，如果一批 spot 的基因表达模式相似，聚类算法可能将它们划分到同一组。

但这里有一个关键问题：

聚类算法只负责分组，并不知道这些组在生物学上代表什么。

例如，算法可能得到 Cluster 0、Cluster 1 和 Cluster 2，但这些编号本身没有生物学含义。

因此，还需要进行**注释**（Annotation，结合标志基因、参考数据和生物学背景，为观测单位或群体赋予生物学解释）。

假设某一群体中免疫细胞相关的标志基因普遍高表达，那么我们可能判断它具有免疫细胞相关特征。

但需要注意，如果一个 spot 同时包含多个细胞，其表达信号可能是多种细胞类型的混合结果。因此，对多细胞 spot 进行注释时，不能直接将其等同于某一个单独的细胞类型。

此外，聚类结果还可能受到**批次效应**（Batch Effect，不同实验批次或处理条件带来的非目标差异）影响。

例如，同一种细胞在两次实验中的测量结果可能存在系统差异，导致算法错误地按实验批次分组，而不是按真实的生物学特征分组。

因此，聚类只是发现潜在群体的第一步，最终解释仍需要生物学证据支持。

12.5 空间分析：把表达模式放回真实组织

普通的基因表达分析主要关注不同观测的表达特征，而空间转录组还多了一项重要信息：**每个 spot 在组织中的真实坐标**。

有了空间坐标，我们就可以进一步研究：

- 哪些基因集中表达在特定组织区域？
- 空间上相邻的 spot 是否具有相似的表达模式？
- 不同组织区域之间是否存在明显的表达边界？

这里还需要区分两种常见的可视化方式。

UMAP 图不是组织的真实空间地图。

UMAP（Uniform Manifold Approximation and Projection）是一种常见的非线性降维方法，可以将高维表达特征映射到二维平面，方便观察数据的局部结构和潜在群体。

但 UMAP 图上的坐标是算法计算出来的，而不是 spot 在组织中的实际位置。

因此，两个点在 UMAP 图中很近，说明它们在降维表示中比较接近，却不代表它们在真实组织里也相邻。

如果想观察组织中的真实空间分布，就需要使用实验提供的空间坐标，而不是 UMAP 坐标。

在 Python 工具中，`Scanpy` 常用于质量控制、归一化、降维和聚类等表达分析；`Squidpy` 则进一步支持空间邻居图、空间统计和组织图像相关分析。[15, 16]

12.6 常见分析步骤总结

分析步骤	主要目的	需要注意的问题
质量控制（QC）	检查数据质量，过滤明显异常的观测	低计数不一定代表低质量
归一化	缓解部分测量总量差异，使表达值更可比	不能消除所有技术误差
特征选择与降维	提取主要表达特征，降低数据维度	高变基因不等于重要致病基因
聚类	将表达模式相似的观测划分为不同群体	聚类编号不具有直接的生物学意义
注释	结合标志基因等证据解释群体身份	多细胞 spot 可能包含混合信号
空间分析	结合真实坐标研究组织中的表达分布	表达相似不代表空间相邻

本章要记住

空间转录组分析通常从质量控制开始，经过归一化、特征选择、降维和聚类，再结合生物学证据进行注释，并利用空间坐标研究组织结构。每一步都在解决不同的问题；算法能够发现数据模式，但这些模式是否具有生物学意义，还需要进一步验证。

Auutuumn

13 算法能够研究哪些问题

13.1 问题一：组织里有哪些不同区域

研究人员想找出结构或表达不同的区域，例如某些组织层、肿瘤内部或边缘。这样的区域叫**空间域**（spatial domain）。一种区域可以包含多类细胞，同一种细胞也可以出现在多个区域。

从 CS 看，这涉及聚类、表征学习或分割。但空间相邻的点不一定同类，模型过度平滑可能把真实边界抹掉。空间域标签回答的是“这里属于什么区域”，不一定回答“这里的细胞是什么类型”。

13.2 问题二：混合区域里有什么细胞

一个 spot 中含有多种细胞时，测到的是混合表达。**反卷积**（deconvolution），就是尝试从混合信号推断各类成分。它类似已知不同乐器的大致音色，再分析一段混合声音里各自的贡献。

一些方法使用单细胞数据作为参考，相当于提供不同细胞类型的表达模板，再推断空间位置的组成。输出可能是类型丰度、相对贡献或比例，要按方法定义解释；RNA 贡献比例不自动等于细胞数量比例。cell2location 是相关方法的一个例子。[17]

13.3 问题三：能否从图像预测表达

给模型一个组织图像块，让它输出一组基因的表达值，这可以看作多输出回归或多模态学习。它利用形态与表达之间的统计关联；预测结果仍是推断，不能当作新完成的 RNA 实验。

13.4 问题四：哪些信号在空间上变化

研究人员会寻找与位置有关的表达模式，例如某个信号在某个区域更明显。这样的基因可称为**空间变异基因**（spatially variable genes，SVG）。表达变化很大却分布随机，与呈现有组织的空间梯度，是不同现象。

13.5 问题五：哪些细胞可能相互影响

细胞可以通过分子信号相互影响。**配体**（ligand）是与受体结合的信号分子等；**受体**（receptor）是接收相关信号的分子组件。算法结合表达、空间关系和已有配体受体知识，提出候选通信关系。CellChat 是相关推断框架的一个例子。[18]

空间靠近或 RNA 共表达都不是通信发生的完整证明。需要进一步研究对应蛋白质、下游变化或实验干预。CS 在这里帮助提出和检验假设，而不是只输出一张漂亮的网络。

本章要记住

先把生物问题翻译成明确的输入与输出，再选择算法。区域、细胞组成、预测表达和候选通信关系是不同的输出。

14 用一个问题串起科研全过程

14.1 从问题开始，而不是从模型开始

贯穿全文的问题是：**这张肿瘤组织切片中的免疫细胞主要在哪里？**为了回答它，先明确实验记录的是单个细胞还是混合 spot，并确认哪些表达信号和参考数据能帮助识别免疫细胞。

14.2 第一步：分清观察与推断

实验直接提供的是记录到的分子信号与对应位置。若有组织图像，它还提供形态信息。“这个位置含有多少免疫细胞”通常还需要注释或反卷积，属于基于观测的推断。

14.3 第二步：定义我们要比较的区域

肿瘤内部与边缘怎样确定？可能来自专家对图像的标注，也可能来自其他有依据的分析。必须说明区域定义，否则“更多在内部”没有明确的比较对象。标注是参照信息，但也可能存在不确定性。

14.4 第三步：选择与测量单位相符的方法

单细胞数据可以在有依据的注释后统计不同区域的细胞分布。混合 spot 数据需要意识到区域内可能包含多种细胞，必要时推断类型丰度，不能强制把整个 spot 都判成单一细胞身份。

14.5 第四步：看结果是否真的支持描述

把结果画回组织，检查是否与图像和标志表达相符；同时比较数量、密度或丰度等明确指标。内部面积大时，单纯看总数量可能产生误导。因此要提前定义“更多”是总数更多、单位面积更多，还是组成比例更高。

例如，对可以按细胞计数的数据，设区域 r 中免疫细胞数为 $n_{\text{immune},r}$，区域面积为 A_r，区域内总细胞数为 $n_{\text{all},r}$，则

$$\text{免疫细胞密度} = \frac{n_{\text{immune},r}}{A_r}, \qquad \text{免疫细胞比例} = \frac{n_{\text{immune},r}}{n_{\text{all},r}}.$$

两者分别回答“单位面积有多少”和“细胞中占多少”。分母须大于零；若方法只输出相对 RNA 贡献，就不能直接把它当成这里的细胞数。

14.6 第五步：决定能把结论说到哪里

在这一张切片上看到了某种分布，可以形成针对这份样本的观察。如果要推广到一类患者，则需要更多独立供体和合适的实验设计。如果要解释分布为何形成，还需要机制或干预证据。

阶段	一句话表述
测量	这个位置记录到哪些 RNA 信号
推断	这些信号可能由哪些细胞产生
比较	不同区域的分布是否有明确差异
验证	额外证据和独立样本是否支持这个结果
解释	什么机制可能造成差异，仍需哪些实验

本章要记住

进入科研后，不只问模型能做什么，还要问输入是什么证据、输出是什么假设，以及怎样验证它。

15 从 CS 模型到可信科学结论

15.1 大量位置不等于大量独立患者

一名患者的一张切片可以产生数千个位置，但这些位置共享供体和局部环境。数千个 spot 不能当作数千名患者。模型评估和统计推断都要明确独立样本单位。**供体**就是提供组织样本的个体。

15.2 训练、测试怎样分，取决于想验证什么

随机拆同一张切片的相邻位置，可以研究同一切片内的插值能力，但不能直接证明模型对新患者泛化。如果目标是新患者，通常应按供体划分；如果目标是新切片，就需要说明切片与供体之间的关系。

例如，同一患者的两张切片分属训练集和测试集，仍不能把这个设置称为对“未见患者”的测试。划分单位应与想宣称的泛化范围一致。

特征选择、参考构建或参数调节如果用到了测试数据，也要说明。允许使用无标签目标数据的设置，与完全不见目标数据的泛化设置，回答的不是同一个问题。

15.3 已有算法结果未必就是地面真值

Ground truth 常译为真值，实际研究中的参照可能是专家区域标注、独立实测，也可能是某个已有算法的输出。它们的证据强度不同。一个模型更像已有模型，不必然表示它更接近真实生物状态。

15.4 差异表达不直接证明原因

比较两组时发现某个基因表达不同，称为**差异表达**。它可以提示值得研究的现象，但差异可能来自细胞组成、状态、测量方式等。**FDR**（false discovery rate，假发现率）用于控制大量检验中的假发现问题；它不代替差异幅度和生物学解释，也不应直接解释为某一项具体结论为假的概率。

如果提出“某个基因导致了某种现象”，通常需要比相关性更强的证据，例如合适的干预实验。仅凭观察数据，表述应停留在数据实际支持的范围内。

15.5 读论文时先回答五个问题

1. 研究的是哪种组织，想回答什么生物问题？
2. 一行是什么，表达值是怎样得到的？
3. 模型输出是直接观测，还是推断结果？
4. 用什么参照和独立数据验证？
5. 比简单方法多解决了哪个具体困难？

理解检查

空间转录组把表达与位置关联；算法帮助组织和推断信息；生物结论仍需要与问题相匹配的验证。现在请从“组织薄片”开始，依次讲清测量、矩阵、位置、算法输出和验证之间的关系。

第四部分

术语回查与延伸阅读

第 16–17 章：回到概念，继续学习

这一部分要理解什么

用术语表回查前文的概念与常见混淆，再按学习进度阅读基础名词、数据对象与分析工具文档。无需一次记住所有术语。

Auutuumn

16 核心术语回查

16.1 如何使用这份术语表

这一章用于回查，不需要背诵。先用左侧术语找到前文已经建立的直觉，再按具体论文或实验补充细节。

16.2 核心术语与常见混淆

术语	最初的理解	容易混淆的地方
细胞 Cell	组织里的基本结构与功能单位	不是每个空间观测都等于一个细胞
组织 Tissue	细胞与周围材料形成的结构	组织含有布局与结构关系
DNA	保存遗传信息的分子	DNA 不会因为转录而全部变成 RNA
基因 Gene	DNA 上具有功能的特定区段	基因存在不等于当前高表达
RNA 与 mRNA	RNA 是一类分子，mRNA 是其中一种	部分 RNA 不被翻译成蛋白质
蛋白质 Protein	氨基酸链形成的功能分子	RNA 数量不直接等于蛋白质数量
转录与翻译	制造 RNA 与按 mRNA 制造蛋白质	两者是不同步骤
基因组与转录组	遗传信息与当时的 RNA 集合	保存的信息与表达状态不同
转录本 Transcript	转录产生的 RNA 产物	同一基因可能有不同版本的产物
基因表达	基因信息被用于产生功能产物	RNA 数据中常指相关 RNA 信号水平
细胞类型与状态	相对稳定的身份与当前活动情况	一个聚类可能反映类型或状态
标志基因 Marker	帮助识别身份或状态的表达线索	一个标志通常不够确证身份
Panel	预先选定的测量基因名单	不在名单中不等于零表达
Bulk 与 scRNA-seq	混合组织与单细胞的 RNA 测量	测量总体与区分个体是不同层次
Spot 与 bin	捕获区域与合并网格区域	区域边界不自动等于细胞边界
Barcode 与 UMI	位置等标签与分子去重线索	UMI 不用于标注细胞类型
Read 与 count	序列读段与流程汇总后的计数	扩增可使多个 reads 来自同一分子
Counts 与归一化值	计数与经过尺度处理的数值	必须按数据状态解释
配准 Registration	将坐标与图像等信息对齐	单位、缩放和方向错误会造成错位
AnnData 与 H5AD	数据对象与常见文件格式	文件格式不能保证处理质量
聚类与注释	算法分组与生物学解释	编号没有自带身份标签
UMAP 与空间坐标	表达的低维表示与实际组织位置	UMAP 图不是组织地图
空间域与反卷积	找组织区域与拆解混合表达	区域标签与细胞组成是不同输出
HVG 与 SVG	表达变异信息与空间变化信息	变异大不一定有空间规律
配体与受体	参与信号传递的分子与接收组件	通信候选仍需要验证
供体 Donor	提供组织样本的个体	很多位置不等于很多独立供体

17 来源和下一步阅读

17.1 按学习进度安排下一步阅读

先读 NHGRI 的基础名词页面，再用本文的矩阵例子理解数据。理解到第 11 章后，可以读 AnnData 文档；理解到第 12 章后，再看 Scanpy 与 Squidpy 的基础示例。暂时不必先啃复杂算法论文。

面向本科生，可以先做到能解释术语、读懂矩阵和区分观察与推断；面向准备进入科研的研究生，再重点检查测量单位、数据处理状态、独立样本与验证设计。两条路径沿用同一条理解主线。

17.2 参考来源

下列 18 项来源沿用原 PDF 的编号与链接。工具文档页面可能随版本更新，实际使用时应结合所用版本阅读。

[1] National Cancer Institute (NCI). *Organ*：器官与组织层次. https://www.cancer.gov/publications/dictionaries/cancer-terms/def/organ

[2] National Human Genome Research Institute (NHGRI). *Deoxyribonucleic Acid (DNA)*：*DNA* 的结构与信息. https://www.genome.gov/genetics-glossary/Deoxyribonucleic-Acid-DNA

[3] NHGRI. *Talking Glossary*：基因、染色体、基因组等基础术语. https://www.genome.gov/genetics-glossary

[4] NHGRI. *Transcription*：转录. https://www.genome.gov/genetics-glossary/Transcription

[5] NHGRI. *Messenger RNA (mRNA)*：信使 *RNA*. https://www.genome.gov/genetics-glossary/Messenger-RNA-mRNA

[6] NHGRI. *Protein*：蛋白质. https://www.genome.gov/genetics-glossary/Protein

[7] NHGRI. *Translation*：翻译. https://www.genome.gov/genetics-glossary/Translation

[8] NHGRI. *Gene Expression*：基因表达. https://www.genome.gov/genetics-glossary/Gene-Expression

[9] NHGRI. *Transcriptome Fact Sheet*：转录组. https://www.genome.gov/about-genomics/fact-sheets/Transcriptome-Fact-Sheet

[10] NHGRI. *RNA-seq*：*RNA* 测序的基本原理. https://www.genome.gov/genetics-glossary/RNA-seq

[11] Ståhl 等，2016. *Visualization and analysis of gene expression in tissue sections by spatial transcriptomics. Science.* 空间转录组原始研究。https://www.science.org/doi/10.1126/science.aaf2403

[12] 10x Genomics. *Glossary of Terms*：*UMI* 等实验术语. https://www.10xgenomics.com/support/cn/software/cell-ranger-arc/latest/getting-started/glossary-of-terms

[13] 10x Genomics. *Spatial Transcriptomics*：空间 *RNA* 检测技术示例. https://www.10xgenomics.com/spatial-transcriptomics

[14] AnnData 文档. *AnnData API*：数据对象及字段. https://anndata.readthedocs.io/en/stable/generated/anndata.AnnData.html

[15] Scanpy 文档. *Clustering*：预处理与聚类基础流程. https://scanpy.readthedocs.io/en/stable/tutorials/basics/clustering.html

[16] Palla 等，2022. *Squidpy: a scalable framework for spatial omics analysis. Nature Methods.* 空间分析框架。https://www.nature.com/articles/s41592-021-01358-2

[17] Kleshchevnikov 等，2022. *Cell2location maps fine-grained cell types in spatial transcriptomics. Nature Biotechnology.* 反卷积方法示例。https://www.nature.com/articles/s41587-021-01139-4

[18] Jin 等，2021. *Inference and analysis of cell-cell communication using CellChat. Nature Communications.* 通信推断方法示例。https://www.nature.com/articles/s41467-021-21246-9